



Jueves de Big Data 3/4 Analizando datos con Python

Jueves de Big Data en Sevilla

25/10/2018 Machine learning, una introducción

08/11/2018 Blockchain

22/11/2018 Analizando datos con Python

13/12/2018 Data Augmentation, haciendo grandes algoritmos con pocos datos













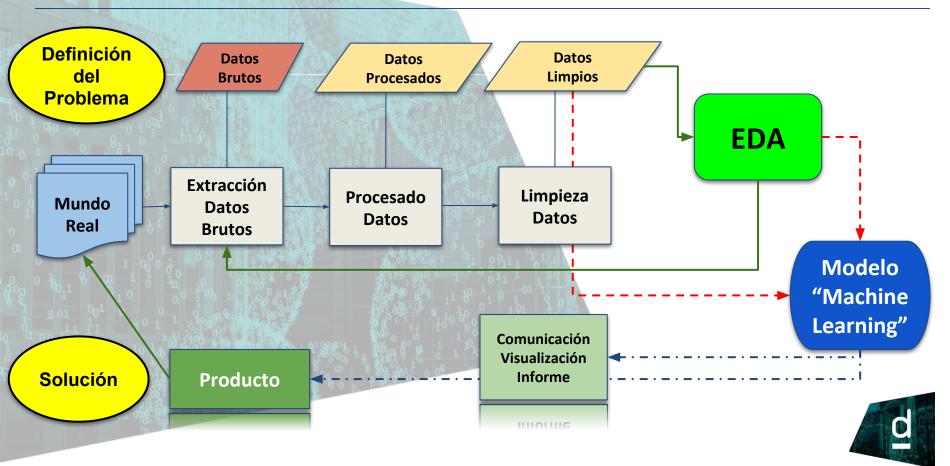


Índice

- 1. Proceso de Ciencia de Datos ("Data Science")
- Etapas de un EDA ("Exploratory Data Analysis")
- 3. Python como herramienta
- 4. Librería NumPy
- 5. Librería Pandas
- 6. Visualización: Matplotlib, Seaborn
- 7. Entornos de trabajo: Anaconda, Jupyter, Spyder
- 8. Ejemplo



Proceso Ciencia de Datos



Etapas de un EDA

"Exploratory Data Analysis" es una actitud, un estado de flexibilidad, una voluntad de buscar aquellas cosas que creemos que no están allí, también aquellas que creemos que sí están.

— John Tukey (1977)

- Tipos de datos
- Espacio de la solución ("target")
- Espacio de las variables ("features")
- Variables categóricas
- Variables numéricas
- Relación entre solución y variables
- Relación entre variables

- Valores únicos
- Valores perdidos ("Missing")
- Valores cero
- Rangos válidos de valores
- Outliers
- Distribución de valores (media, mediana, desviación est., percentiles, máx-min, sesgo)

Python como herramienta

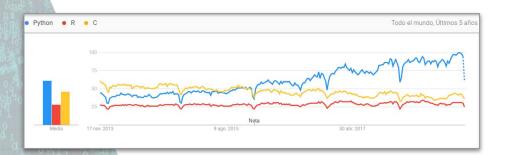




Python: lenguaje de programación interpretado (no compilado), creado por Guido Van Rossum en 1989 con un objetivo de que fuera fácil de usar y aprender

Motivos de su popularidad:

- 1. Comunidad que lo respalda
- 2. Esponsorizado por Google
- 3. Tiene Big Data
- 4. Tiene librerías para casi todo
- 5. Es eficiente y fiable
- 6. Es accesible



Librerías:

Python: 140000

(3700 específicas de DS)

<u>R</u>: 12000

(6000 específicas de DS)



NumPy: Arrays y vectorización (1/2)

Numpy (Numerical Python) es, probablemente, la librería más importante de todo el lenguaje Python (más allá de las incluídas en la librería interna estándar). Al mismo tiempo, es la librería de álgebra lineal más conocida y potente que hay a día de hoy.

Incluído en Numpy:

- <u>ndarray</u>, un eficiente array multidimensional con una rápida aritmética orientada a array
- <u>Funciones matemáticas</u> para operaciones rápidas sobre los arrays enteros, sin hacer bucles
- Herramientas para lectura/escritura a disco, trabajando con ficheros mapeados en memoria
- <u>Álgebra lineal, generación de aleatorios, transformada de Fourier</u>
- Una API a C para conectar NumPy con librerías escritas en C, C++ y FORTRAN





NumPy: Arrays y vectorización (2/2)

Principales aplicaciones en análisis de datos:

- Muy rápidas operaciones vectorizadas, para manipulación, limpieza, selección, filtrado y transformación
- Algoritmos sobre arrays comunes: ordenado, únicos y operaciones sobre conjuntos ("set")
- Eficiente estadística descriptiva, agregación y resumen de datos
- Alineación y manipulación de datos relacionales, para "merging" y "joining"
- Lógica condicional usando expresiones de arrays en lugar de bucles "if-elif-else"

Razones de la importancia de NumPy:

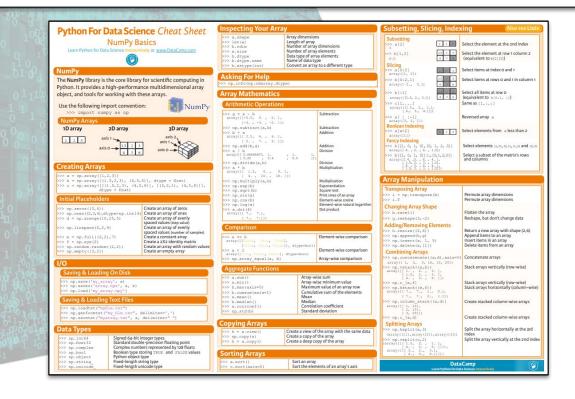
- Está diseñado para arrays de datos muy grandes
- Internamente almacena los datos en bloques de memoria contigua, independiente de los otros objetos de Python
- Los algoritmos están escritos en C





NumPy: Cheat Sheet

https://s3.amazonaws.com/assets.datacamp.com/blog_assets/Numpy_Python_Cheat_Sheet.pdf





Pandas: Series y DataFrames

Pandas es una librería construida sobre Numpy que nos permite tratar datos, principalmente <u>estructurados</u> ("<u>tablas</u>"), de forma sencilla, cómoda y rápida

Los principales elementos son: los "DataFrame", que son objetos tabulares orientados en columnas, y las "Series", objetos array unidimensionales

Características principales de Pandas:

- Mezcla la base de alto rendimiento en computación de NumPy, con la manipulación flexible de hojas de cálculo y bases de datos relacionales (como SQL)
- Permite indexación sofisticada, para facilitar la transformación, selección, filtrado y todo tipo de operaciones sobre los <u>DATOS</u>
- Funcionalidad integrada de series temporales
- Manipulación flexible de datos "missing" (drop, ffill, bfill, interpolate, ...)
- "Merging" y otras operaciones relacionales que se usan habitualmente en bases de datos (SQL)



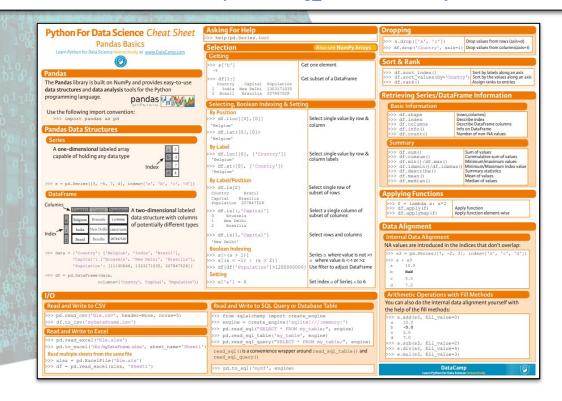






Pandas: Cheat Sheet

https://s3.amazonaws.com/assets.datacamp.com/blog_assets/PandasPythonForDataScience.pdf





Matplotlib: visualización de datos 1

La Visualización es una de las tareas más importantes en el Análisis de Datos.

Matplotlib, es la librería por excelencia de creación de gráficos 2D en Python. El proyecto lo empezó John Hunter en 2002, para tener un interfaz gráfico parecido a Matlab en Python.

Objetivos que se marcó John Hunter cuando creó Matplotlib:

- Gráficos debería ser de alta calidad para publicaciones
- Debe tener salida Postscript para inclusión en documentos TeX
- Debe permitir embeberse en una interfaz gráfica de usuario (GUI) para desarrollo de aplicaciones
- Debe ser suficientemente fácil para entenderlo y extenderlo
- Generar gráficos debe ser fácil





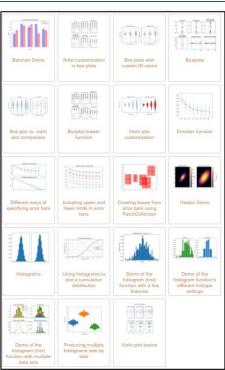
Matplotlib: visualización de datos 1

Tipos de gráficos:

- Líneas
- Histograma
- Barras
- Contornos
- Polares
- Scatter
- Pastel
- Multipanel y grids
- Boxplots
- Violinplots
- Barras de error
- Hexbin
- Densidad
- Animación
- ...





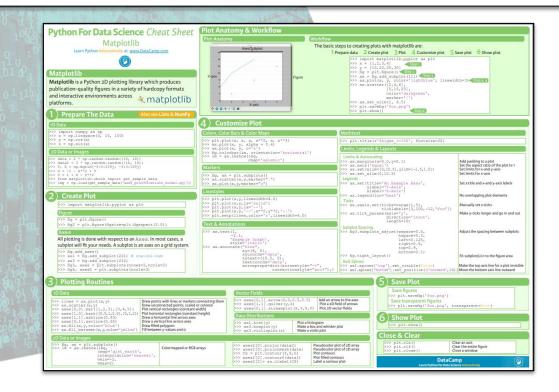






Matplotlib: Cheat Sheet

https://s3.amazonaws.com/assets.datacamp.com/blog_assets/Python_Matplotlib_Cheat_Sheet.pdf





Seaborn: visualización de datos 2

Seaborn es una librería basada en Matplotlib para hacer gráficos estadísticos, e integrada con las estructuras de Pandas, con un interfaz de alto nivel y visualizaciones muy cuidadas

Características principales de Seaborn:

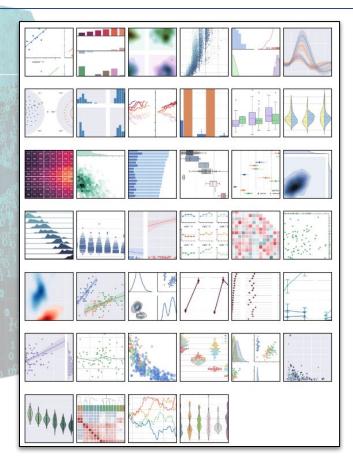
- API orientada a datasets para <u>examinar relaciones</u> entre múltiples variables
- Especial soporte para variables categóricas para mostrar observaciones y agregar estadística
- Opciones para visualizar <u>univariable</u> y <u>multivariable</u>
- Estimación automática de <u>regresiones lineales</u>
- Visualización general de datasets complejos
- Multi-plot de alto nivel para construir visualizaciones complejas
- Control conciso de los estilos de Matplotlib con temas incluídos
- Herramientas para elegir <u>paletas para revelar patrones</u>



Seaborn: visualización de datos 2

Tipos de gráficos:

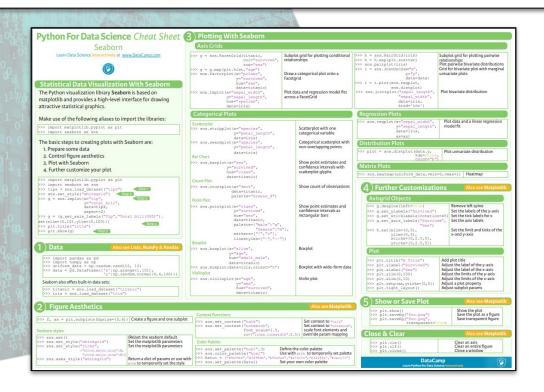
- <u>Relacionales</u> (relación, scatter y líneas)
- <u>Categóricos</u> (stripplot, swarmplot, boxplot, catplot, violinplot, boxen, barras, contorno)
- <u>Distribución</u> (joint, pair, densidad, kde, rug)
- Regresión (Implot, regplot, residplot)
- <u>Matrices</u> (heatmap, clustermap)
- <u>Multi-plots</u> (facetgrid, pair grids, joint grids)
-





Seaborn: Cheat Sheet

https://s3.amazonaws.com/assets.datacamp.com/blog assets/Python Seaborn Cheat Sheet.pdf





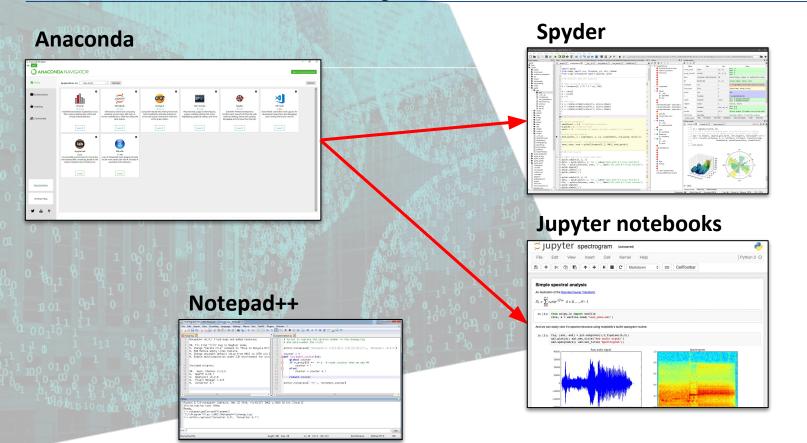
Entornos de trabajo





jupyter







¿Tienes alguna pregunta?





